

Autômatos Celulares Neurais Quaterniônicos

Carlos G. Ribeiro¹, Lucas R. Pereira¹

¹Instituto de Matemática, Estatística e Computação Científica
Universidade Estadual de Campinas (UNICAMP)
Caixa Postal 6065 – 13083-970 – Campinas – SP – Brasil

c232791@dac.unicamp.br, l251341@dac.unicamp.br

Abstract. *This paper introduces the Quaternionic Neural Cellular Automaton (Q-NCA) for bio-inspired morphogenesis. The impact of the Hamilton product on parametric efficiency and spatial anisotropy is evaluated. While Q-NCA significantly reduces parameters compared to real-valued baselines, full quaternionic coupling constrains hidden degrees of freedom, requiring wider layers ($H_q = 96$) to preserve visual quality. Furthermore, the algebraic structure does not eliminate anisotropy, as rigid orthogonal filters continue to dominate morphogenesis, merely altering internal pixel dynamics under rotation while increasing computational costs.*

Resumo. *Este trabalho introduz o Autômato Celular Neural Quaterniônico (Q-NCA) para morfogênese bioinspirada. Avalia-se o impacto do produto de Hamilton na eficiência paramétrica e na anisotropia espacial. Embora o Q-NCA reduza drasticamente o número de parâmetros frente ao baseline real, o acoplamento quaterniônico restringe graus de liberdade ocultos, exigindo camadas mais largas ($H_q = 96$) para manter a qualidade visual. Ademais, a estrutura algébrica não elimina a anisotropia; filtros ortogonais rígidos continuam dominando a morfogênese, alterando apenas a dinâmica interna dos pixels sob rotação e elevando o custo computacional.*

1. Introdução

Autômatos celulares são sistemas dinâmicos discretos formados por uma malha de células que evoluem iterativamente a partir de regras locais. Em cada passo, o estado de uma célula depende do estado da própria célula e de sua vizinhança. Embora essa definição seja simples, ela permite a emergência de comportamentos coletivos complexos, razão pela qual autômatos celulares são utilizados como modelos conceituais de auto-organização, formação de padrões e interação. No contexto contemporâneo de aprendizado profundo, os Autômatos Celulares Neurais (do inglês *Neural Cellular Automata* - NCA) substituem regras manuais por funções diferenciáveis parametrizadas por redes neurais convolucionais, permitindo ajustar a dinâmica por retropropagação.

O ponto de partida deste trabalho é o modelo clássico proposto em *Growing Neural Cellular Automata* [Mordvintsev et al. 2020]. Trata-se de um experimento de morfogênese computacional onde uma grade de células precisa aprender a crescer e estabilizar um padrão visual a partir de uma semente unitária. No arranjo padrão, o vetor de estado de cada célula aloca os primeiros canais para a imagem visível (RGBA) e o restante para canais ocultos que atuam como sinalização química ou memória local. Como a regra

de atualização é idêntica para todas as células, o sistema emula um organismo biológico onde cada parte compartilha o mesmo código genético, mas expressa estados fenotípicos distintos conforme o ambiente local.

Essa formulação perceptiva original carrega um forte viés geométrico: o cálculo dos gradientes locais é feito projetando filtros nos eixos x e y de um referencial estático. Esse detalhe é importante porque a regra aprendida passa a depender de um sistema de coordenadas externo ao organismo, este fenômeno é conhecido como anisotropia. Trabalhos posteriores tornaram explícita essa limitação, o *Isotropic NCA* [Mordvintsev et al. 2022], argumenta que o NCA original apresenta anisotropia da regra aprendida, isto é, a dinâmica não é invariante a rotações, e propõe formas de removê-la por quebra de simetria ou objetos invariantes a rotação/reflexão. Essa limitação também motivou a proposta de *Stearable NCA* [Randazzo et al. 2023], o qual transfere a orientação para o estado interno das células, permitindo que cada célula rotacione individualmente. Em outras palavras, a redução da anisotropia tornou-se um problema central na evolução desses NCA.

Redes neurais vetoriais e hipercomplexas têm sido estudadas como alternativas a redes reais convencionais em tarefas com dados multicanais. A motivação é que, enquanto redes tratam canais como coordenadas independentes, redes vetoriais processam grupos de canais como entidades algébricas e, por isso, incorporam *a priori* relações entre características [Valle 2024]. Redes de valor-hipercomplexo são casos particulares de *V-nets* em que a álgebra possui propriedades adicionais, como identidade bilateral e, muitas vezes, significado geométrico [Valle et al. 2024]. Entre essas álgebras, os quatérnios são particularmente atraentes porque representam naturalmente tuplas de quatro componentes e preservam acoplamentos internos por meio do produto de Hamilton, além de terem uso consolidado em problema de geometria de rotação [Cybenko 1989, Leshno et al. 1993].

A hipótese deste estudo é formulada em caráter exploratório: investiga-se se uma formulação quaterniônica do NCA, ao impor um acoplamento algébrico estruturado entre grupos de canais, altera de modo mensurável a eficiência paramétrica, a capacidade de representação e a sensibilidade do modelo. Não se assume, *a priori*, que a álgebra dos quatérnios induza invariância ou equivariância rotacional no plano bidimensional. O objetivo é avaliar se tal restrição estrutural no espaço de estados modifica o comportamento do autômato quando submetido a rotações e se esse efeito compensa a redução no número de parâmetros livres.

2. Fundamentação teórica

2.1. Álgebras hipercomplexas e quatérnios

Adotando as definições estabelecidas em [Valle 2024, Schafer 1961], revisam-se as operações em álgebras hipercomplexas sob a ótica de modelos profundos de valor vetorial.

Definição 1 Uma álgebra hipercomplexa $\mathcal{A}$ de dimensão d sobre $\mathbb{R}$ é um espaço vetorial equipado com uma operação bilinear $\times : \mathcal{A} \times \mathcal{A} \rightarrow \mathcal{A}$ e uma identidade bilateral $\mathbf{1}$ satisfazendo $\mathbf{1} \times x = x \times \mathbf{1} = x, \forall x \in \mathcal{A}$.

Fixada a base canônica ordenada $\mathcal{E} = \{\mathbf{1}, e_1, \dots, e_{d-1}\}$ de $\mathcal{A}$, qualquer elemento $x \in \mathcal{A}$ é mapeado por suas coordenadas através do isomorfismo linear $\varphi : \mathcal{A} \rightarrow \mathbb{R}^d$,

onde $\varphi(\mathbf{x}) = [\xi_0, \dots, \xi_{d-1}]^T$ de modo que $\mathbf{x} = \xi_0 \mathbf{1} + \sum_{i=1}^{d-1} \xi_i \mathbf{e}_i$. A bilinearidade garante que o produto de dois elementos dependa apenas das constantes de estrutura da base, $\mathbf{e}_i \times \mathbf{e}_j = \sum_{k=0}^{d-1} p_{ijk} \mathbf{e}_k$. Operacionalmente, isso se traduz em um produto matriz-vetor:

$$\varphi(\mathbf{x} \times \mathbf{y}) = \mathcal{M}_L(\mathbf{x})\varphi(\mathbf{y}) \quad (1)$$

onde $\mathcal{M}_L(\mathbf{x}) = \sum_{i=0}^{d-1} \xi_i \mathbf{P}_{i:}^T \in \mathbb{R}^{d \times d}$, e $\mathbf{P}_{i:}^T$ representa a transposta da i -ésima fatia do tensor de constantes de estrutura p_{ijk} .

2.1.1. A álgebra dos quatérnions

Os quatérnions ($\mathbb{H}$) definem uma álgebra hipercomplexa de dimensão $d = 4$ associada à base $\mathcal{E} = \{\mathbf{1}, \mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3\}$. A dinâmica multiplicativa segue as regras clássicas de Hamilton:

$\mathbb{H}$	$\mathbf{1}$	$\mathbf{e}_1$	$\mathbf{e}_2$	$\mathbf{e}_3$
$\mathbf{1}$	1	$\mathbf{e}_1$	$\mathbf{e}_2$	$\mathbf{e}_3$
$\mathbf{e}_1$	$\mathbf{e}_1$	-1	$\mathbf{e}_3$	$-\mathbf{e}_2$
$\mathbf{e}_2$	$\mathbf{e}_2$	$-\mathbf{e}_3$	-1	$\mathbf{e}_1$
$\mathbf{e}_3$	$\mathbf{e}_3$	$\mathbf{e}_2$	$-\mathbf{e}_1$	-1

(2)

Dados $\mathbf{x}, \mathbf{y} \in \mathbb{H}$, com $\mathbf{x} = \xi_0 + \xi_1 \mathbf{i} + \xi_2 \mathbf{j} + \xi_3 \mathbf{k}$ e $\mathbf{y} = \eta_0 + \eta_1 \mathbf{i} + \eta_2 \mathbf{j} + \eta_3 \mathbf{k}$, expressa-se o produto à esquerda $\mathcal{M}_L(\mathbf{x})$ por meio de um operador matricial real que simula o comportamento da álgebra:

$$\varphi(\mathbf{x} \times \mathbf{y}) = \begin{bmatrix} \xi_0 & -\xi_1 & -\xi_2 & -\xi_3 \\ \xi_1 & \xi_0 & -\xi_3 & \xi_2 \\ \xi_2 & \xi_3 & \xi_0 & -\xi_1 \\ \xi_3 & -\xi_2 & \xi_1 & \xi_0 \end{bmatrix} \begin{bmatrix} \eta_0 \\ \eta_1 \\ \eta_2 \\ \eta_3 \end{bmatrix} = \mathcal{M}_L(\mathbf{x})\varphi(\mathbf{y}) \quad (3)$$

3. Autômatos celulares neurais

3.1. NCA real

Seja $\Omega = \{1, \dots, H\} \times \{1, \dots, W\}$ uma grade discreta bidimensional. No modelo de referencial real, o estado de uma célula na coordenada $p = (i, j) \in \Omega$ no instante t é um vetor:

$$\mathbf{x}_t(p) \in \mathbb{R}^C, \quad C = 16 \quad (4)$$

Por convenção, as primeiras quatro dimensões carregam as informações visíveis de RGBA, e as 12 posições restantes para sinais e memória interna [Mordvintsev et al. 2020]. A etapa de percepção local é dada por:

$$\mathcal{P}_\theta(\mathbf{x}_t) = [K_0 \circledast \mathbf{x}_t, K_x(\theta) \circledast \mathbf{x}_t, K_y(\theta) \circledast \mathbf{x}_t] \quad (5)$$

onde K_0 é o filtro identidade e a dupla $K_x(\theta), K_y(\theta)$ representa os operadores de Sobel rotacionados em um ângulo θ . O operador $\circledast$ indica convoluções espaciais aplicadas de forma estrita canal a canal. A regra de transição baseia-se em uma rede MLP convolucional de passo 1×1 :

$$\Delta \mathbf{x}_t(p) = f_\psi(\mathcal{P}_\theta(\mathbf{x}_t)(p)) \quad (6)$$

onde f_ψ é compartilhada por toda a malha. A atualização efetiva incorpora um caráter estocástico:

$$\mathbf{x}_{t+1}(p) = \mathbf{x}_t(p) + m_t(p)\Delta\mathbf{x}_t(p), \quad m_t(p) \sim \text{Bernoulli}(f) \quad (7)$$

em que, tipicamente $f = 0.5$ [Mordvintsev et al. 2020]. Elementos sem células vivas na vizinhança 3×3 são zerados via máscara de vida, usando o canal α como linha de corte.

3.2. NCA quaterniônico

No arranjo do Q-NCA, as 16 dimensões reais são remapeadas em 4 canais hipercomplexos:

$$\mathbf{q}_t(p) \in \mathbb{H}^{C_q}, \quad C_q = 4, \quad p \in \Omega \quad (8)$$

Isso preserva a dimensionalidade total do espaço de estados, visto que $\mathbb{R}^{16} \cong \mathbb{H}^4$.

A primeira dimensão quaterniônica abriga os canais visíveis:

$$q_{0,t}(p) = \alpha_t(p) + r_t(p)\mathbf{i} + g_t(p)\mathbf{j} + b_t(p)\mathbf{k} \quad (9)$$

enquanto $q_{1,t}$, $q_{2,t}$ e $q_{3,t}$ são quatérnions ocultos usados como memória interna do organismo. No tensor real, os canais são armazenados na ordem

$$[R_0, R_1, R_2, R_3, I_0, I_1, I_2, I_3, J_0, J_1, J_2, J_3, K_0, K_1, K_2, K_3] \quad (10)$$

Desse modo, a operação de projeção visível Π_{vis} isola o bloco necessário:

$$\Pi_{\text{vis}}(\mathbf{x}_t) = [R_0(\mathbf{x}_t), I_0(\mathbf{x}_t), J_0(\mathbf{x}_t), K_0(\mathbf{x}_t)] \quad (11)$$

A extração de características espaciais opera de forma idêntica ao NCA original, porém processando cada componente dos blocos quaterniônicos individualmente, os operadores de Sobel são dados por:

$$K_0 = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \quad K_x = \frac{1}{8} \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}, \quad K_y = K_x^T \quad (12)$$

Para o teste com orientação genérica θ , os operadores são rotacionados:

$$K_x(\theta) = \cos(\theta)K_x - \sin(\theta)K_y, \quad (13)$$

$$K_y(\theta) = \sin(\theta)K_x + \cos(\theta)K_y. \quad (14)$$

Para cada canal quaterniônico q_c ($c \in \{0, 1, 2, 3\}$), o vetor de percepção local assume a forma:

$$\mathcal{P}_\theta(q_c) = [K_0 \otimes q_c, K_x(\theta) \otimes q_c, K_y(\theta) \otimes q_c] \quad (15)$$

onde as convoluções espaciais varrem de forma independente as componentes real, $\mathbf{i}$, $\mathbf{j}$ e $\mathbf{k}$.

3.3. Redes vetoriais, álgebra não degenerada e ativação split

A perspectiva de redes vetoriais é útil porque permite interpretar redes hipercomplexas como redes definidas sobre uma álgebra de dimensão finita em vez de apenas como ”truques” de empacotamento de canais. Em particular, trabalhos recentes mostram que *V-nets* podem ser vistas como modelos reais com restrições que forçam intercorrelação entre canais e podem ser implementadas em bibliotecas padrão como redes reais estruturadas [Valle 2024].

Do ponto de vista teórico, a propriedade mais importante para este trabalho é a álgebra ser não degenerada. A multiplicação precisa preservar informação suficiente entre componentes para que funcionais lineares possam ser representados no espaço vetorial subjacente. O resultado de Valle, Vita e Vieira mostra que, em álgebras não degeneradas e com função ativação *split* derivada de uma função real adequada, redes *V-MLP* de uma camada oculta herdam a propriedade de aproximação universal, incluindo como caso particular as redes quaterniônicas [Valle et al. 2024].

4. Método proposto

4.1. Convolução quaterniônica 1×1

A regra de atualização usa convoluções quaterniônicas pontuais. A Equação (3) dita como projetar o *kernel* quaterniônico em uma matriz real por blocos. Na prática, via *TensorFlow*, instancia-se o tensor hipercomplexo como a variável treinável do modelo; o código-fonte desta implementação está disponível em [Ribeiro and Pereira 2026]. Antes de disparar a convolução bidimensional nativa da biblioteca, uma sub-rotina monta o *kernel* expandido equivalente. Esse arranjo garante que o gradiente flua via retropropagação padrão, forçando os pesos a respeitarem a álgebra de Hamilton ao longo de todo o treinamento.

4.2. Atualização local

A dinâmica de avanço do passo local do Q-NCA é modelada por:

$$\mathbf{h}_t = \phi_{\mathbb{H}} \left(\mathcal{Q}_{1 \times 1}^{(1)}(\mathcal{P}_{\theta}(\mathbf{q}_t)) \right) \quad (16)$$

$$\Delta \mathbf{q}_t = \mathcal{Q}_{1 \times 1}^{(2)}(\mathbf{h}_t) \quad (17)$$

onde:

- $\mathcal{Q}_{1 \times 1}^{(1)}$ é uma camada convolucional quaterniônica 1×1 com H_q canais ocultos;
- $\phi_{\mathbb{H}}$ opera como uma ativação *split*, aplicando a função ReLU componente a componente:

$$\phi_{\mathbb{H}}(a + b\mathbf{i} + c\mathbf{j} + d\mathbf{k}) = \text{ReLU}(a) + \text{ReLU}(b)\mathbf{i} + \text{ReLU}(c)\mathbf{j} + \text{ReLU}(d)\mathbf{k}; \quad (18)$$

- $\mathcal{Q}_{1 \times 1}^{(2)}$ produz um incremento com $C_q = 4$ canais quaterniônicos;
- a segunda camada é inicializada com pesos nulos, reproduzindo o comportamento *do-nothing* do NCA original.

4.3. Atualização estocástica e máscara de vida

A dinâmica do incremento respeita a taxa de disparo $f \in (0, 1]$ via amostragem de Bernoulli:

$$M_t(p) \sim \text{Bernoulli}(f), \quad \tilde{\mathbf{q}}_{t+1}(p) = \mathbf{q}_t(p) + M_t(p)\Delta\mathbf{q}_t(p). \quad (19)$$

O teste de sobrevivência celular monitora a componente real de q_0 :

$$\alpha_t(p) = \text{Re}(q_{0,t}(p)). \quad (20)$$

Uma célula permanece ativa se houver algum elemento maduro na vizinhança imediata:

$$L_t(p) = \mathbf{1} \left[\max_{u \in \mathcal{N}_3(p)} \alpha_t(u) > 0.1 \right] \quad (21)$$

Assim como no NCA original, utilizamos máscaras de vida antes e depois da atualização. A atualização final é

$$\mathbf{q}_{t+1} = L_t^{\text{pre}}(p)L_t^{\text{post}}(p)\tilde{\mathbf{q}}_{t+1}(p) \quad (22)$$

A semente de crescimento ocupa a posição central p_c da malha, inicializada com:

$$q_0(p_c) = 1 + 0\mathbf{i} + 0\mathbf{j} + 0\mathbf{k} \quad (23)$$

Os quatérnios ocultos q_1, q_2, q_3 são inicializados com valor unitário nas quatro componentes, fornecendo uma memória mínima. Todas as demais células começam com estado nulo.

4.4. Função de perda e treinamento com pool de amostras e dano

Sendo $Y \in \mathbb{R}^{H \times W \times 4}$ a imagem alvo em formato RGBA, calcula-se a perda de treino varrendo apenas os quatro canais visíveis extraídos da projeção:

$$\mathcal{L}(\mathbf{q}_T, Y) = \frac{1}{4HW} \sum_{p \in \Omega} \|\Pi_{\text{vis}}(\mathbf{q}_T(p)) - Y(p)\|_2^2 \quad (24)$$

O ciclo de otimização reproduz a estratégia regenerativa clássica do modelo original:

1. amostra-se o horizonte temporal de passos de evolução via $T \sim \mathcal{U}\{64, \dots, 96\}$, com $\mathcal{U}$ sendo uma distribuição uniforme;
2. os estados iniciais de treino são sorteados de um *pool* fixo de memória;
3. o elemento com maior perda do lote é descartado e substituído pela semente pura;
4. as D amostras de menor perda são danificadas por máscaras aleatórias;
5. o autômato processa a grade por T passos;
6. computa-se o erro MSE e aplica-se uma normalização na norma do gradiente:

$$g_k \leftarrow \frac{g_k}{\|g_k\|_2 + \varepsilon}, \quad \varepsilon = 10^{-8} \quad (25)$$

Algorithm 1 Treinamento do Q-NCA regenerativo

- 1: Inicializar modelo $\mathcal{A}_\Theta$, semente s , *pool* $\mathcal{S}$ e alvo Y
 - 2: **for** $n = 1, \dots, N_{\text{train}}$ **do**
 - 3: Amostrar $B \subset \mathcal{S}$
 - 4: Ordenar B por perda decrescente
 - 5: Substituir a pior amostra por $s \in \mathcal{S}$
 - 6: Danificar as D melhores amostras com máscaras aleatórias
 - 7: Sortear $T \sim \mathcal{U}\{64, \dots, 96\}$
 - 8: Evoluir o autômato por T passos: $B \leftarrow \mathcal{A}_\Theta^{(T)}(B)$
 - 9: Calcular $\mathcal{L}(B, Y)$
 - 10: Retropropagar, normalizar gradientes e atualizar Θ
 - 11: Regravar as amostras atualizadas em $\mathcal{S}$
 - 12: **end for**
-

4.5. Experimento computacional

Os detalhes da parametrização adotada nos experimentos constam na Tabela 1.

Tabela 1. Hiperparâmetros dos modelos

Item	NCA real	Q-NCA
Canais reais do estado	16	–
Canais quaterniônicos	–	4
Canal visual	RGBA nos canais 0-3	$q_0 = \alpha + R\mathbf{i} + G\mathbf{j} + B\mathbf{k}$
Canais ocultos	128 reais	32, 64 ou 96 quaterniônicos
<i>Batch size</i>	8	8
<i>Pool size</i>	1024	1024
<i>Fire rate</i>	0,5	0,5
<i>Padding</i> do alvo	16	16
Tamanho do alvo base	40	40
Passos do treino	8000	8000
Passos internos por amostra	uniforme em $\{64, \dots, 96\}$	uniforme em $\{64, \dots, 96\}$
Otimizador	Adam	Adam
Taxa inicial de aprendizado	2×10^{-3}	2×10^{-3}
Decaimento de LR	após 2000 passos, fator 0,1	após 2000 passos, fator 0,1
Regime	<i>regenerating</i>	<i>regenerating</i>
Amostras danificadas por <i>batch</i>	3	3

No NCA de referência real, o operador de percepção triplica o número de canais de entrada. Se a largura da camada oculta é h_r , calcula-se o total de parâmetros livres por:

$$P_{\text{real}} = (3Ch_r + h_r) + (h_rC + C) \quad (26)$$

Fixando $C = 16$ e $h_r = 128$, chega-se a $P_{\text{real}} = 8336$. Já para o Q-NCA, a convolução pontual hipercomplexa consome $4C_q^{\text{in}}C_q^{\text{out}} + 4C_q^{\text{out}}$ termos. Portanto:

$$P_Q = (4 \cdot 3C_qH_q + 4H_q) + (4H_qC_q + 4C_q) \quad (27)$$

Para as dimensões do teste ($C_q = 4$ e $H_q = 96$), o modelo computa com $P_Q = 6544$, confirmando uma redução significativa na carga de parâmetros sob a mesma base de canais estruturais.

Tabela 2. Comparação entre a arquitetura da NCA real e da Q-NCA proposta.

Modelo	Rede	Parâmetros
NCA real	Conv2D (128, 1) Conv2D (16, 1)	8336
Q-NCA	QConv2D (32, 1) QConv2D (4, 1)	2192
Q-NCA	QConv2D (64, 1) QConv2D (4, 1)	4368
Q-NCA	QConv2D (96, 1) QConv2D (4, 1)	6544

5. Resultados e Discussão

Analisa-se o comportamento dos modelos focando na convergência visual das morfologias geradas, na rigidez que a estrutura quaterniônica impõe aos canais ocultos e no comportamento do sistema sob perturbações e rotações na etapa de inferência. O seguinte gráfico apresenta o comportamento da função de perda na escala logarítmica em diferentes configurações em relação a quantidade de canais ocultos (*hidden channels*), assim como a performance do modelo original. As nuvens de pontos foram suavizadas utilizando média móvel de 100 passos.




Figura 1. Curvas de perda (MSE) obtidas durante as 8000 iterações de treinamento para o baseline real e as variantes quaterniônicas avaliadas.

5.1. O impacto do acoplamento quaterniônico nos canais ocultos

Os experimentos indicaram que, embora o Q-NCA preserve rigorosamente a mesma dimensionalidade no espaço de estados em relação ao *baseline* real ($\mathbb{H}^4 \cong \mathbb{R}^{16}$), a imposição

da álgebra quaterniônica nas camadas de transição engessa severamente a dinâmica interna do autômato. A modelagem por quatérnios funciona de maneira satisfatória para tratar os canais visíveis de RGBA, os quais possuem uma forte dependência geométrica e correlação mútua. Contudo, o cenário muda quando se avaliam as variáveis ocultas restantes. Nesse espaço abstrato, a rede necessita de total independência linear para construir livremente suas próprias representações e sinais de controle que ditam a morfogênese.

Ao contrário do modelo real convencional, que emprega uma matriz de pesos cheia com parâmetros livres e independentes na convolução 1×1 , a convolução hipercomplexa obriga os pesos a se repetirem e a vincularem seus sinais conforme a estrutura do produto à esquerda apresentada na Equação (3). Esse forte viés indutivo e restritivo reduz drasticamente a liberdade dos parâmetros treináveis. Como consequência, os resultados sugerem que o acoplamento imposto pela álgebra reduz a independência dos canais ocultos, restringindo a diversidade de transformações lineares disponíveis em comparação com a parametrização real totalmente livre.

O impacto prático dessa restrição de parâmetros livres fica evidente quando se varia a largura oculta (H_q) do modelo hipercomplexo:

- Q-NCA com 32 canais ocultos: O modelo recupera a silhueta e as cores básicas da estrutura alvo, mas falha em sintetizar bordas e detalhes de alta frequência espacial devido à severa limitação de caminhos independentes para o fluxo de gradiente.
- Q-NCA com 96 canais ocultos: Ao expandir a dimensão do espaço hipercomplexo interno, o modelo atinge uma quantidade de parâmetros livres suficiente para compensar o acoplamento algébrico forçado, aproximando satisfatoriamente a fidelidade visual da rede convencional.




Figura 2. Amostras visuais extraídas do *pool* de estados estáveis após a convergência. O acoplamento restritivo degrada os detalhes finos em (b), exigindo a expansão da camada oculta hipercomplexa em (d) para recuperar a nitidez do *baseline* (a).

5.2. Análise da anisotropia e instabilidade sob rotação

Buscou-se avaliar se o viés indutivo clássico da álgebra quaterniônica traria algum grau de blindagem contra a anisotropia do NCA real. Para colocar essa premissa à prova, aplicaram-se matrizes de rotação espacial $\theta \in [0, 2\pi]$ nos filtros de percepção de Sobel ($K_x(\theta)$ e $K_y(\theta)$) em fase de teste.

Os resultados experimentais indicam que o viés hipercomplexo não resolve o problema. O Q-NCA apresentou o mesmo comportamento instável do modelo clássico real

diante de ângulos ausentes no histórico de treinamento: o padrão morfológico deforma-se após poucos passos de atualização.

A análise fina da trajetória dos estados sugere que o produto quaterniônico mexe exclusivamente com a dinâmica de mistura interna de cores e sinais em cada pixel durante o giro, deixando o sistema vulnerável à orientação espacial externa. Isso reforça que a anisotropia observada nesses sistemas é ditada prioritariamente pelo cálculo de gradientes locais em eixos estáticos x e y . Alterações algébricas aplicadas somente sobre o vetor de estados celular não fornecem invariância rotacional ao sistema, isso é coerente com as conclusões obtidas por [Mordvintsev et al. 2022].

5.3. Custo computacional

O Q-NCA opera com menos parâmetros em termos absolutos para as proporções testadas, mas o tempo de execução em GPU superou consideravelmente a marca do NCA real. Esse comportamento reflete o custo computacional de simular o produto de Hamilton em *frameworks* modernos. A necessidade de realizar operações sucessivas de fatiamento de tensores, inversões de sinal e concatenações estruturadas para montar o *kernel* real equivalente a cada passo de tempo cobra um preço alto em processamento.

6. Conclusão e trabalhos futuros

Este trabalho apresentou o Q-NCA, uma variante hipercomplexa voltada a Autômatos Celulares Neurais, avaliando o impacto de operadores estruturados no desenvolvimento morfogenético e na sensibilidade direcional do sistema. Os resultados obtidos apontam que, embora os quatérnios capturem bem estruturas geométricas, impor esse acoplamento rígido em quadrivetores nas variáveis ocultas reduz a capacidade de aprendizado em redes compactas. Os dados mostram também que travar a álgebra no espaço de estados não mitiga a anisotropia gerada por filtros perceptivos ortogonais rígidos.

Para investigações futuras, identificam-se duas frentes principais de pesquisa:

1. Álgebras de acoplamento brando: Testar a formulação de NCAs com base na álgebra dos números complexos ($\mathbb{C}$). Reduzir a restrição estrutural para blocos de duas variáveis pode dar mais flexibilidade aos canais ocultos de sinalização.
2. Arquiteturas com álgebras híbridas: Construir modelos com vetores de estados mistos, aplicando o formalismo quaterniônico estritamente sobre as dimensões visíveis de RGBA e mantendo convoluções reais padrão para os canais internos de memória.

Referências

- Cybenko, G. (1989). Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314.
- Leshno, M., Lin, V. Y., Pinkus, A., and Schocken, S. (1993). Multilayer feedforward networks with a nonpolynomial activation function can approximate any function. *Neural Networks*, 6(6):861–867.
- Mordvintsev, A., Randazzo, E., and Fouts, C. (2022). Growing isotropic neural cellular automata.

- Mordvintsev, A., Randazzo, E., Niklasson, E., and Levin, M. (2020). Growing neural cellular automata. *Distill*. <https://distill.pub/2020/growing-ca>.
- Randazzo, E., Mordvintsev, A., and Fouts, C. (2023). Growing steerable neural cellular automata.
- Ribeiro, C. G. and Pereira, L. R. (2026). QNCA: Quaternionic Neural Cellular Automata Implementation. <https://github.com/lrp-math/QNCA>. Acesso em: 4 jul. 2026.
- Schafer, R. (1961). *An Introduction to Nonassociative Algebras*. Project Gutenberg.
- Valle, M. E. (2024). Understanding vector-valued neural networks and their relationship with real and hypercomplex-valued neural networks: Incorporating intercorrelation between features into neural networks. *IEEE Signal Processing Magazine*, 41(3):49–58.
- Valle, M. E., Vital, W. L., and Vieira, G. (2024). Universal approximation theorem for vector- and hypercomplex-valued neural networks.